

BIG DATA

PROYECTO FINAL

Javier Bris



Javier Bris Miñambres

RESPONSABLE DEL DESARROLLO DE LA APLICACIÓN

Fecha: 16 de septiembre de 2026

BIG DATA

PROYECTO FINAL
Javier Bris Miñambres



Índice

Índice.....	2
1. Introducción	3
2. Dataset y preparación de datos.....	3
2.1 Descripción del dataset	3
2.2 Preparación del entorno en Cassandra	4
2.3 Carga y tratamiento de datos con PySpark	5
3. Análisis exploratorio de datos (EDA)	5
3.1 Distribución de clientes y <i>churn</i> por tipo de tarifa	5
3.2 <i>Churn</i> por duración de contrato.....	8
4. Análisis estadístico.....	11
4.1 Media y desviación estándar.....	11
4.2 Interpretación de variables numéricas.....	11
5. Análisis de correlación.....	13
5.1 Interpretación de la matriz de correlación.....	13
6. Modelado predictivo / clustering	15
6.1 Elección del enfoque: Árboles de decisión.....	15
6.2 Interpretación de resultados.....	16
7. Conclusiones y recomendaciones de negocio	19
7.1 Factores clave del <i>churn</i>	19
7.2 Acciones recomendadas para la empresa.....	20



1. Introducción

En el presente proyecto se busca aplicar los conocimientos adquiridos a lo largo del Máster en Big Data y Análisis de Datos. El objetivo principal es desarrollar un caso práctico realista en el que, a partir de un conjunto de datos de clientes de una empresa de telecomunicaciones, se realice un análisis completo del comportamiento de los usuarios y su relación con la baja del servicio (*churn*).

Es importante destacar que el proyecto no está definido completamente de forma cerrada, por lo que será necesario tomar decisiones durante su desarrollo y adaptar determinadas soluciones en función de la interpretación de los datos. Estas decisiones serán justificadas al final del informe científico.

El presente caso simula la incorporación a un puesto como Analista Big Data en la empresa Tokio Telecom, cuyo objetivo es analizar el comportamiento de sus clientes y entender los factores que influyen en la cancelación del servicio. Para ello, se dispone del dataset `customer_churn_10k.csv`, que contiene información demográfica, de uso y de comportamiento de los clientes.

A lo largo del proyecto se llevarán a cabo distintas tareas de análisis, almacenamiento, procesamiento y modelado de datos, utilizando tecnologías como Apache Cassandra y PySpark, con el objetivo final de extraer conclusiones de negocio que permitan mejorar la retención de clientes.

2. Dataset y preparación de datos

2.1 Descripción del dataset

La primera tarea consiste en conocer el tipo de datos disponibles. Para ello, se analiza su estructura y se clasifican en la siguiente tabla:

Nombre del campo	Tipo de dato
CustomerID	Categórica nominal identificadora
Age	Numérica entera
Gender	Categórica binaria
Tenure	Numérica entera
Usage Frequency	Numérica entera

BIG DATA



Support Calls	Numérica entera
Payment Delay	Numérica entera
Subscription Type	Categórica nominal
Contract Length	Categórica ordinal
Total Spend	Numérica decimal
Last Interaction	Numérica entera
Churn_YesNo	Categórica binaria objetivo

Las variables del dataset se han clasificado según su naturaleza y el tipo de información que representan. Las variables numéricas contienen valores cuantitativos sobre los clientes y permiten realizar operaciones matemáticas y análisis estadísticos. Las variables categóricas describen características cualitativas, como el género, el tipo de suscripción o la duración del contrato. Dentro de estas últimas, se distinguen variables binarias, que únicamente pueden adoptar dos valores posibles, como Gender y Churn_YesNo. Por último, CustomerID se ha considerado una variable categórica nominal identificadora, ya que su función es identificar de forma única a cada cliente y no representa una variable susceptible de análisis estadístico o predictivo.

2.2 Preparación del entorno en Cassandra

Para la realización de esta práctica se ha utilizado Apache Cassandra a través del entorno online proporcionado por Killercode. Esta plataforma permite trabajar con Cassandra sin necesidad de realizar una instalación local, facilitando la creación de estructuras de datos, la inserción de registros y la ejecución de consultas mediante el lenguaje CQL (Cassandra Query Language).

El objetivo de este apartado es diseñar las tablas necesarias para responder a las consultas planteadas en el ejercicio, siguiendo el modelo de almacenamiento propio de Cassandra y teniendo en cuenta los patrones de acceso a los datos requeridos.

Para obtener más detalles, consulte el *Anexo 9.1: Consultas en Cassandra* del presente informe.

El entorno de trabajo se configuró mediante Docker, descargando la imagen oficial de Cassandra 3.11 y creando una red para la comunicación entre contenedores.

BIG DATA



Posteriormente, se ejecutó el contenedor de Cassandra y se accedió a la consola CQL mediante cqlsh.

Se creó un keyspace y una tabla adaptada al dataset de churn de clientes. Debido a las limitaciones del entorno, los datos fueron insertados manualmente mediante sentencias INSERT. Como solo se introdujeron los nueve primeros registros de clientes, las conclusiones obtenidas deben interpretarse teniendo en cuenta esta limitación y no pueden considerarse representativas del dataset completo.

Finalmente, se realizaron consultas filtradas para obtener clientes con tarifa "Basic" y clientes con tarifa "Basic" y contrato "Annual", utilizando ALLOW FILTERING para permitir el filtrado sobre columnas no indexadas. Los resultados de este análisis fueron que existen tres clientes con tarifa "Basic" y ningún cliente con tarifa "Basic" y contrato anual ("Annual").

2.3 Carga y tratamiento de datos con PySpark

En este apartado se emplea PySpark en Google Colab para analizar el conjunto de datos de clientes. En primer lugar, se carga el fichero CSV en un DataFrame de PySpark para realizar operaciones de agregación y análisis sobre los datos. Para mayor detalle del código utilizado, consulte el *Anexo 9.2: Carga y tratamiento de datos con PySpark*.

3. Análisis exploratorio de datos (EDA)

Tras cargar el dataset en Google Colab, se ha utilizado PySpark para cargar y analizar el conjunto de datos de clientes mediante un DataFrame. En primer lugar, se ha estudiado la distribución de clientes según el tipo de tarifa contratada (Subscription Type), calculando tanto el número de clientes como el porcentaje de abandono (churn) para cada modalidad de contrato. Posteriormente, los resultados se han representado mediante gráficos de barras que facilitan su interpretación. Para mayor detalle del código utilizado, consulte el *Anexo 9.3: Distribución de clientes, churn y duración de contratos*.

3.1 Distribución de clientes y churn por tipo de tarifa

El análisis muestra que la distribución de clientes entre las tarifas Basic, Standard y Premium es relativamente equilibrada, siendo la tarifa Premium la que concentra un mayor número de clientes.

BIG DATA




Figura 1. Clientes por tipo de tarifa.

La distribución de clientes por tipo de tarifa es bastante equilibrada, aunque la tarifa Premium concentra ligeramente más clientes que Standard y Basic.

En cuanto al porcentaje de abandono, las diferencias entre las tres modalidades son reducidas, aunque la tarifa Basic presenta la *tasa de churn* más elevada (58,27 %), seguida de Standard (56,68 %) y Premium (55,28 %).




Figura 2. Porcentaje de abandono por tipo de tarifa.

El gráfico muestra que las tasas de abandono por tipo de tarifa son muy similares, por lo que esta variable, analizada de forma aislada, no parece ser el principal factor explicativo del churn.




Figura 3. Clientes y porcentaje de abandono por tipo de tarifa.

Esta comparación permite observar que, aunque la distribución de clientes por tarifa es equilibrada, las diferencias en la tasa de abandono son reducidas. Por tanto, el tipo de tarifa no debería analizarse de forma independiente, sino junto con otras variables como duración del contrato, llamadas a soporte o retrasos en pagos.

3.2 Churn por duración de contrato

A continuación, se ha repetido el mismo procedimiento para la variable Contract Length.

En primer lugar, se observa que la modalidad Annual es la más frecuente, con 4.046 clientes, seguida por los contratos Quarterly, con 3.970 clientes. Por último, los contratos Monthly representan el grupo menos numeroso, con 1.984 clientes.




Figura 4. Clientes por duración del contrato.

Este gráfico complementa el análisis del churn, ya que permite comparar el tamaño de cada grupo de clientes antes de interpretar sus tasas de abandono.

Respecto al porcentaje de abandono, los resultados muestran diferencias más acusadas que las observadas en el análisis por tipo de tarifa. Los contratos Annual presentan una tasa de churn del 45,06 %, mientras que los contratos Quarterly alcanzan un 46,98 %. Por su parte, los contratos Monthly registran una tasa de abandono del 100 %, lo que indica que, dentro del conjunto de datos analizado, todos los clientes con este tipo de contrato han abandonado el servicio.




Figura 5. Tasa de churn por duración del contrato.

Este gráfico permite visualizar de forma directa que el contrato mensual es el segmento con mayor riesgo de abandono, por lo que constituye un punto prioritario para las acciones de fidelización.

Desde un punto de vista de negocio, estos resultados sugieren que la duración del contrato tiene una influencia mucho mayor sobre el abandono de los clientes que el tipo de tarifa contratada. Los clientes con contratos de mayor duración muestran una mayor fidelización, mientras que los contratos mensuales presentan un riesgo de abandono considerablemente superior.

En consecuencia, una posible estrategia empresarial consistiría en incentivar la contratación de planes de mayor duración mediante descuentos, promociones o beneficios adicionales, con el objetivo de aumentar la retención de clientes y reducir la tasa de abandono.

BIG DATA

PROYECTO FINAL
Javier Bris Miñambres



4. Análisis estadístico

4.1 Media y desviación estándar

En este apartado se realiza un análisis descriptivo de las variables numéricas del conjunto de datos mediante PySpark. Para ello, se calculan la media y la desviación estándar de cada variable cuantitativa, excluyendo el campo CustomerID, ya que actúa como identificador único de cada cliente y no aporta información estadística relevante para el análisis.

La media permite conocer el valor promedio de cada variable, mientras que la desviación estándar mide el grado de dispersión de los datos respecto a dicha media. Estas medidas facilitan una primera aproximación al comportamiento del conjunto de datos antes de realizar análisis más avanzados.

Para mayor detalle del código utilizado, consulte el *Anexo 9.4: Análisis estadístico, media y desviación estándar*.

4.2 Interpretación de variables numéricas

Tras calcular la media y la desviación estándar de las variables numéricas mediante PySpark, se observa que la edad media de los clientes es de 39,26 años, con una desviación estándar de 12,49 años, lo que indica que el conjunto de clientes presenta una distribución relativamente amplia de edades.

La antigüedad media de los clientes (Tenure) es de 30,95, con una desviación estándar de 17,14, reflejando que conviven clientes con poca permanencia junto a otros con una relación más prolongada con la empresa.

En cuanto a la frecuencia de uso del servicio (*Usage Frequency*), se obtiene un valor medio de 15,77 usos, con una desviación estándar de 8,63, lo que muestra una variabilidad considerable en el nivel de utilización del servicio por parte de los clientes.

El número medio de llamadas al servicio de atención al cliente (*Support Calls*) es de 3,59, con una desviación estándar de 3,08. Esto indica que, aunque muchos clientes apenas necesitan contactar con el soporte, existen otros que realizan un número significativamente mayor de consultas o incidencias.

BIG DATA

Respecto al retraso en los pagos (*Payment Delay*), la media es de 13,03, con una desviación estándar de 8,26, lo que refleja diferencias importantes en el comportamiento de pago de los clientes.

Por otro lado, el gasto total (*Total Spend*) presenta una media de 633,32 unidades monetarias y una desviación estándar de 240,47, siendo la variable con mayor dispersión absoluta. Este resultado pone de manifiesto que existen diferencias significativas en el importe gastado por los clientes, lo que podría estar relacionado con el tipo de tarifa contratada, la antigüedad o el nivel de uso del servicio.

Finalmente, la variable *Last Interaction* presenta una media de 14,49 y una desviación estándar de 8,62, indicando que el tiempo transcurrido desde la última interacción también varía de forma apreciable entre los distintos clientes.

En conjunto, el análisis descriptivo muestra que el conjunto de datos presenta una variabilidad moderada en la mayoría de las variables estudiadas. Estas diferencias entre clientes justifican la realización de análisis posteriores, ya que variables como la antigüedad, la frecuencia de uso, el retraso en los pagos o el gasto total podrían estar relacionadas con la probabilidad de abandono (*churn*) y aportar información relevante para el desarrollo de modelos predictivos.

A continuación, se presenta una tabla resumen con el conjunto de medias y desviaciones estándar obtenidas:

Variable	Media	Desviación estándar	Interpretación breve
Edad (Age)	39,26	12,49	Distribución amplia de edades.
Antigüedad (Tenure)	30,95	17,14	Clientes con permanencias muy distintas.
Frecuencia de uso (Usage Frequency)	15,77	8,63	Variabilidad en el uso del servicio.
Llamadas a soporte (Support Calls)	3,59	3,08	Indicador posible de incidencias.
Retraso en el pago (Payment Delay)	13,03	8,26	Diferencias relevantes en comportamiento de pago.
Gasto total (Total Spend)	633,32	240,47	Variable con mayor dispersión absoluta.
Última interacción (Last Interaction)	14,49	8,62	Diferencias en la recencia de contacto.

5. Análisis de correlación

Con el objetivo de estudiar la relación existente entre las variables numéricas del conjunto de datos, se realizó un análisis de correlación mediante PySpark. La correlación permite medir el grado de asociación lineal entre dos variables, tomando valores comprendidos entre -1 y 1. Un valor próximo a 1 indica una correlación positiva fuerte, un valor próximo a -1 indica una correlación negativa fuerte y un valor cercano a 0 refleja una relación lineal débil o inexistente.

Para calcular la matriz de correlación fue necesario transformar las variables numéricas en un único vector de características, ya que este es el formato requerido por las librerías de Machine Learning de Spark (MLlib). Posteriormente, se calculó la matriz de correlación utilizando el coeficiente de Pearson.

Una matriz de correlación permite analizar la relación entre varias variables de forma conjunta.

El coeficiente de Pearson indica si dos variables tienden a aumentar o disminuir juntas y con qué intensidad, tomando valores comprendidos entre -1 y 1.

Para mayor detalle del código utilizado, consulte el *Anexo 9.5: Análisis de correlación*.

5.1 Interpretación de la matriz de correlación

A continuación, se realiza un análisis de correlación entre variables numéricas usando la matriz de correlación obtenida mediante el código incluido en el *Anexo 9.5: Análisis de correlación*.

	Age	Tenure	Usage Frequency	Support Calls	Payment Delay	Total Spend	Last Interaction
Age	1.000.000	-0.000693	-0.004411	0.175940	0.053811	-0.076583	0.033162
Tenure	-0.000693	1.000.000	-0.031740	-0.018698	0.007875	0.013821	0.002084
Usage Frequency	-0.004411	-0.031740	1.000.000	-0.032477	-0.033654	0.029837	-0.010357
Support Calls	0.175940	-0.018698	-0.032477	1.000.000	0.164219	-0.225403	0.073694
Payment Delay	0.053811	0.007875	-0.033654	0.164219	1.000.000	-0.122547	0.044035
Total Spend	-0.076583	0.013821	0.029837	-0.225403	-0.122547	1.000.000	-0.062719
Last Interaction	0.033162	0.002084	-0.010357	0.073694	0.044035	-0.062719	1.000.000

BIG DATA

PROYECTO FINAL

Javier Bris Miñambres




Figura 6. Correlaciones numéricas más relevantes.

La representación gráfica facilita la comparación entre correlaciones positivas y negativas, mostrando que las relaciones detectadas son débiles pero útiles para interpretar posibles patrones de comportamiento.

Tras calcular la matriz de correlación mediante PySpark, se observa que la mayoría de las variables presentan valores de correlación cercanos a cero, lo que indica la ausencia de relaciones lineales fuertes entre las variables analizadas.

La relación positiva más destacable se encuentra entre "Age" y "Support Calls", con un coeficiente de correlación de 0,176. Aunque la relación es débil, podría indicar que los clientes de mayor edad tienden ligeramente a realizar más llamadas al servicio de soporte.

Por otro lado, destaca la correlación negativa entre "Support Calls" y "Total Spend", con un valor de -0,225. Este resultado indica una relación inversa débil, sugiriendo que los clientes que realizan más llamadas al servicio de atención al cliente tienden a presentar

BIG DATA



un gasto total ligeramente inferior. Desde un punto de vista de negocio, esto podría indicar una mayor insatisfacción o existencia de problemas en clientes con menor valor económico para la compañía.

También se observa una correlación positiva entre *"Support Calls"* y *"Payment Delay"* (0,164), lo que podría indicar que los clientes con mayores dificultades de pago tienden a contactar más con el servicio de soporte. Esta relación podría ser relevante para identificar clientes con mayor riesgo de abandono.

Además, existe una correlación negativa entre *"Payment Delay"* y *"Total Spend"* (-0,123), aunque de intensidad baja. Esto podría indicar que los clientes con mayores retrasos en pagos presentan un gasto ligeramente inferior.

En general, los resultados muestran que no existe una única variable numérica con una relación lineal fuerte respecto al resto. Por tanto, el comportamiento de los clientes y su posible abandono no parece estar explicado por una sola característica, sino que probablemente depende de la combinación de diferentes factores como el uso del servicio, la interacción con soporte, los retrasos en pagos y el gasto realizado.

6. Modelado predictivo / clustering

El objetivo es desarrollar un modelo predictivo capaz de identificar aquellos clientes con mayor probabilidad de abandonar la empresa (*customer churn*). Anticipar el abandono permite a la organización diseñar estrategias de fidelización dirigidas a los clientes con mayor riesgo, reduciendo la pérdida de ingresos y mejorando la rentabilidad del negocio.

6.1 Elección del enfoque: Árboles de decisión

Para resolver este problema se ha seleccionado un algoritmo de Aprendizaje Supervisado basado en Árboles de Decisión (Decision Tree Classifier), ya que la variable objetivo (*Churn_YesNo*) es categórica y toma únicamente dos valores: Yes y No. Este algoritmo permite clasificar nuevos clientes según su probabilidad de abandono y ofrece una interpretación sencilla de las reglas de decisión aprendidas.

Para mayor detalle del código utilizado, consulte *el Anexo 9.6: Decision Tree Classifier (Árbol de decisión)*, donde se explica el proceso completo de transformación de variables

BIG DATA



categorías, construcción del vector de características, entrenamiento del modelo y evaluación de resultados.

6.2 Interpretación de resultados

Para construir el modelo predictivo se utilizó un Árbol de Decisión en PySpark. Antes del entrenamiento fue necesario transformar las variables categóricas mediante *StringIndexer* y *OneHotEncoder*, y agrupar todas las variables explicativas en una única columna de características mediante *VectorAssembler*. De esta forma, el modelo pudo trabajar de forma conjunta con variables numéricas y categóricas.

El conjunto de datos se dividió en dos partes: un 80 % para el entrenamiento del modelo y un 20 % para la evaluación posterior. Además, se aplicó una búsqueda de hiperparámetros mediante *GridSearch*, probando distintas profundidades del árbol, y se utilizó validación cruzada con cinco particiones, siendo la configuración más adecuada para reducir el riesgo de sobreajuste. Un árbol demasiado pequeño puede ser demasiado simple y no aprender bien los patrones, mientras que uno demasiado profundo puede aprender demasiado los datos de entrenamiento. Por eso probamos diferentes profundidades y comparamos su rendimiento.

Tras entrenar el modelo y aplicarlo sobre el conjunto de prueba, se obtuvo una Accuracy de 0,9621, equivalente aproximadamente a un 96,21 % de predicciones correctas. Este resultado indica que el árbol de decisión presenta un elevado nivel de precisión global en la clasificación de los clientes según su probabilidad de abandono.

Además de la Accuracy, se calculó la métrica AUC, obteniéndose un valor de 0,9666. Al tratarse de un valor cercano a 1, el resultado muestra que el modelo tiene una capacidad muy elevada para distinguir entre clientes que abandonan la compañía y clientes que permanecen en ella. La curva ROC representada confirma esta capacidad de discriminación, ya que la tasa de verdaderos positivos aumenta rápidamente manteniendo una tasa de falsos positivos reducida.

Conjunto	Accuracy	AUC	Interpretación
Test	0,9621	0,9666	El modelo mantiene una elevada capacidad de clasificación sobre datos no vistos.




Figura 7. Curva ROC del modelo de árbol de decisión.

La curva ROC muestra que el modelo distingue correctamente entre clientes que abandonan y clientes que permanecen en la compañía. Al comparar train y test, se puede comprobar si el rendimiento se mantiene en datos no utilizados durante el entrenamiento.




Figura 8. Curva ROC.

La gráfica muestra la relación entre la tasa de verdaderos positivos y la tasa de falsos positivos, con valores entre 0,0 y 1,0. En el eje X, la curva alcanza aproximadamente el valor 0,05, mientras que en el eje Y llega a 1. A partir de ese punto, la recta ya no crece más en el eje Y. Esto significa que el modelo consigue identificar el **100 % de los clientes que abandonan**, mientras que solo clasifica incorrectamente como "abandono" aproximadamente al **5 % de los clientes que no abandonan**.

Aunque los resultados son muy positivos, deben interpretarse con cautela. Una Accuracy elevada resume el porcentaje global de aciertos, pero no muestra por sí sola si el modelo clasifica con la misma eficacia a los clientes que abandonan y a los que no abandonan. Por este motivo, la incorporación del AUC y de la curva ROC aporta una evaluación más completa del rendimiento del modelo.



7. Conclusiones y recomendaciones de negocio

7.1 Factores clave del *churn*

El análisis realizado sobre el conjunto de datos de clientes ha permitido identificar diferentes variables relacionadas con el comportamiento de abandono (*churn*). En primer lugar, el análisis descriptivo mostró que el tipo de tarifa contratada no presenta diferencias muy significativas en las tasas de abandono. Aunque la tarifa Basic presentó el mayor porcentaje de churn (58,27 %), seguida de Standard (56,68 %) y Premium (55,28 %), las diferencias entre modalidades son reducidas, por lo que el tipo de suscripción por sí solo no parece ser un factor determinante del abandono.

En cuanto a la duración del contrato, se observaron diferencias más relevantes. Los clientes con contrato mensual presentaron una tasa de churn del 100 %, mientras que los clientes con contratos anuales y trimestrales mostraron tasas considerablemente inferiores (45,06 % y 46,98 %, respectivamente). Estos resultados sugieren que los clientes con contratos de menor duración pueden presentar una mayor probabilidad de abandono, posiblemente debido a un menor compromiso con la compañía.

El análisis de correlación entre variables numéricas mostró que no existe una relación lineal fuerte entre la mayoría de los atributos analizados. Sin embargo, algunas relaciones pueden aportar información relevante, como la correlación negativa entre Support Calls y Total Spend (-0,225), que indica que los clientes con mayor interacción con el servicio de soporte tienden ligeramente a presentar un menor gasto total. También se observó una relación positiva entre Support Calls y Payment Delay (0,164), lo que podría indicar una mayor interacción con atención al cliente entre usuarios con posibles dificultades de pago.

Finalmente, el modelo predictivo basado en un Árbol de Decisión obtuvo una Accuracy del 96,21 % y un AUC de 0,9666 sobre el conjunto de prueba. Estos resultados muestran una elevada capacidad de clasificación y discriminación entre clientes según su probabilidad de abandono. Además, el uso de GridSearch y validación cruzada permitió seleccionar una configuración más adecuada del árbol y reducir el riesgo de sobreajuste.



7.2 Acciones recomendadas para la empresa

A partir de los resultados obtenidos, se pueden plantear diferentes estrategias orientadas a reducir la tasa de abandono y mejorar la fidelización de clientes.

En primer lugar, la compañía debería prestar especial atención a los clientes con contratos mensuales, ya que presentan un mayor riesgo de abandono frente a aquellos con contratos de mayor duración. Una posible estrategia sería incentivar la migración hacia contratos trimestrales o anuales mediante descuentos, ventajas exclusivas o programas de fidelización.

Además, sería recomendable establecer sistemas de alerta temprana basados en modelos predictivos como el desarrollado en este proyecto. Dado que el árbol de decisión obtuvo una Accuracy del 96,21 % y un AUC de 0,9666, podría utilizarse como herramienta de apoyo para priorizar clientes con mayor probabilidad de abandono, activar campañas para evitar abandonos y aplicar acciones preventivas de fidelización antes de que se produzca la baja.

También se deberían analizar los clientes con un elevado número de llamadas al servicio de soporte o con retrasos en los pagos, ya que estas variables muestran cierta relación con otros indicadores de riesgo. En estos casos podrían aplicarse acciones como mejoras en la atención al cliente, resolución rápida de incidencias o planes personalizados de pago.

Por último, aunque el tipo de tarifa no parece ser un factor decisivo por sí mismo, la empresa podría utilizar la combinación de esta variable junto con otros indicadores del comportamiento del cliente para diseñar campañas de retención más personalizadas. De esta forma, las decisiones comerciales no se basarían únicamente en la modalidad contratada, sino en una visión global del perfil y comportamiento de cada usuario.