



Predicción del churn con Big Data y Machine Learning

GridSearch y validación cruzada · ROC–AUC en train y test

Tokio Telecom · Proyecto Final Big Data

Javier Bris Miñambres · 16 Septiembre de 2026



Problema de Negocio y Objetivo del Proyecto

¿Qué es el Churn?


Abandono o cancelación de clientes que dejan de utilizar los servicios de la empresa.

¿Por qué es importante?

Detectar clientes con riesgo de abandono permite diseñar estrategias de retención personalizadas y reducir pérdida de ingresos.

Objetivo del Proyecto:

Analizar los factores asociados al churn y desarrollar un modelo predictivo capaz de identificar clientes con mayor probabilidad de abandono.






Dataset y Metodología

Características del Dataset:

- 10.000 clientes analizados
- Variables demográficas: Edad, Género
- Variables de comportamiento: Antigüedad, Frecuencia de uso, Llamadas de soporte, Retrasos de pago
- Variables de suscripción: Tipo de tarifa, Duración del contrato
- Variable objetivo: Churn (Sí/No)

Stack Tecnológico:





Apache Cassandra - Almacenamiento Distribuido

Propósito:

Almacenamiento distribuido y escalable de datos de clientes.

Operaciones Realizadas:


- Creación del keyspace "churn"
- Creación de tabla "customers" con campos del dataset
- Inserción de registros mediante CQL
- Consultas filtradas sobre clientes con tarifa Basic

Importante - Limitación del Entorno:

Debido a las limitaciones del entorno Killercoda, solo se insertaron 9 registros de prueba.

Estos resultados NO son representativos del dataset completo de 10.000 clientes.


El análisis completo se realizó con PySpark en Google Colab.



Tokio.



Distribución de Clientes por Tarifa



Una base equilibrada

La distribución entre los tres tipos de suscripción es notablemente homogénea, lo que garantiza representatividad estadística en el análisis.

3.233

Clientes Basic

3.361


Clientes Standard

3.596

Clientes Premium



Churn por Tipo de Tarifa



Clientes Basic en mayor riesgo


Aunque la diferencia entre tarifas no es dramática, los clientes con plan **Basic presentan la tasa de abandono más elevada** con un 58,27%, superando en casi 3 puntos al plan Premium.



La tarifa Basic requiere atención prioritaria en la estrategia de retención.




Cientes y churn por duración del contrato



Menos clientes, pero máximo riesgo: el contrato mensual alcanza un 100% de churn.



Churn por Duración de Contrato



Anual

45,06%

Riesgo bajo — mayor compromiso
compromiso del cliente

Trimestral

46,98%

Riesgo moderado — seguimiento
recomendado

Mensual

100%

CRÍTICO — abandono total del segmento



Los clientes con contrato mensual abandonan al 100% — intervención inmediata requerida.



Entrenamiento validado: GridSearch + CV (5 folds)

1 SEPARAR

80 / 20

80% para entrenamiento
20% para evaluación final

2 OPTIMIZAR

GridSearch

Prueba distintas
profundidades y selecciona la
mejor configuración.


3 VALIDAR

5 folds

Cinco bloques
reducen el riesgo
de sobreajuste.

4 EVALUAR

Curva ROC - Test - AUC 0,9666



Esquema con valores del informe - sustituir por exportación PySpark

RESULTADOS DISPONIBLES
EN TEST

96,21% Accuracy · 0,9666 AUC



Resultados del Modelo

Resultado del Modelo

96,21%

Accuracy — Decision Tree

Predicción altamente precisa de clientes en riesgo de churn.

El modelo de árbol de decisión alcanzó un **96,21% de precisión**, identificando de forma fiable a los clientes con mayor probabilidad de abandono.

Patrones clave detectados

- **Tipo de contrato**
Variable más determinante del churn
- **Tarifa del cliente**
Basic vs. Premium como factor diferenciador
- **Antigüedad**
Clientes nuevos presentan mayor riesgo



Conclusiones

Resumen de Hallazgos Principales:

1 Tipo de Tarifa

El tipo de tarifa presenta diferencias de churn relativamente pequeñas (máximo 3 puntos porcentuales). Basic muestra el mayor churn, pero no es el factor determinante.

3 Correlaciones Débiles

Las correlaciones entre variables numéricas son generalmente débiles, indicando que el churn es un fenómeno multifactorial.

2 Duración del Contrato

La duración del contrato muestra una diferencia mucho más marcada, especialmente en clientes mensuales (100% churn). Este es el factor más discriminante identificado.

4 Potencial del Modelo Predictivo

El modelo de Decision Tree obtuvo una Accuracy del 96,21%, mostrando potencial para utilizar modelos predictivos como herramienta de apoyo a la retención.

Conclusión de Negocio:

El análisis de datos y Machine Learning pueden ayudar a pasar de una estrategia reactiva ante el abandono a una estrategia preventiva y personalizada de retención.



Factores Clave y Recomendaciones

Factores Observados:

- Duración del contrato (especialmente contratos mensuales)
- Diferencias reducidas entre tipos de tarifa
- Número de llamadas a soporte
- Retrasos en los pagos
- Combinación de múltiples características del cliente

Recomendaciones:

- Incentivar contratos de mayor duración
- Crear sistemas de alerta temprana para clientes con riesgo de churn
- Diseñar campañas de retención personalizadas
- Prestar especial atención a clientes con señales de riesgo (retrasos en pagos, elevada interacción con soporte)
- Implementar programas de onboarding robustos para clientes nuevos